

Estrategias para la modelización y pronóstico de series temporales interrumpidas: evaluación comparada con aplicación al transporte urbano de Rosario

Tesina de grado



Universidad Nacional de Rosario
Facultad de Ciencias Económicas y Estadística
Licenciatura en Estadística

Alumno: Santini, Franco Andrés
Directora: Mag. Méndez, Fernanda

Año 2026

Tabla de contenidos

1. Introducción	3
2. Objetivos	5
2.1 Objetivo general	5
2.2 Objetivos específicos	5
3. Metodología	6
3.1 Conceptos básicos de series de tiempo	6
3.1.1 Autocorrelación	7
3.1.2 Pronósticos	9
3.2 ARIMA/SARIMA	9
3.3 Modelos altamente adaptativos (ETS)	12
3.4 Modelos de intervención (Regresión Dinámica con errores ARIMA)	16
3.5 Métodos contrafactuales	17
3.5.1 Establecer como faltante (<i>set to missing</i>)	17
3.5.2 Lo que podría haber ocurrido (<i>what might have been</i>)	18
3.6 Métodos de combinación (<i>ensemble</i>)	18
3.7 Métricas de evaluación	21
3.7.1 Raíz del error cuadrático medio (RMSE)	21
3.7.2 Error absoluto medio (MAE)	21
3.7.3 Error porcentual absoluto medio (MAPE)	21
3.7.4 Puntuación de Winkler (<i>Winkler Score</i>)	22
3.7.5 Ajuste y evaluación de los modelos	22
4. Aplicación	24
4.1 Análisis descriptivo	24
4.2 Ajuste de modelos	30
4.2.1 ARIMA/SARIMA	30
4.2.2 ETS	32
4.2.3 Modelos de intervención	34
4.2.4 Métodos contrafactuales	36
4.2.5 Ensemble	40
4.3 Resultados comparativos de pronóstico	42
4.4 Diagnóstico y validación de modelos	44
5. Conclusión	45
6. Aporte y futuras líneas	47

7. Anexo	48
8. Bibliografía	75

Agradecimientos

Quiero expresar mi más sincero agradecimiento a todas aquellas personas que me acompañaron a lo largo de este camino.

En primer lugar, a mis padres, por su apoyo incondicional, su esfuerzo constante y por darme la oportunidad de estudiar.

A mi hermano, por ser mi guía, por escuchar cada queja antes y después de los exámenes, y por aconsejarme todo el tiempo.

A todos mis amigos de la facu, por acompañarme muchas horas de estudio en la biblioteca y por meet, y por sobre todas las cosas hacer este camino muchísimo más fácil.

A mis amigos del pueblo, por bancarme tantos años, por ser mi cable a tierra y por alegrarse de mis logros como si fueran suyos.

A todos mis profesores, por su dedicación, compromiso y por transmitir sus conocimientos y experiencias.

A Nanda, mi directora, por acompañarme, apoyarme y confiar en mí para llevar adelante este gran trabajo.

Finalmente, a la Universidad Nacional de Rosario, por brindarme el espacio, la formación y las oportunidades para crecer tanto en lo académico como en lo personal.

A todos ellos, muchas gracias.

Resumen

Esta tesina investiga estrategias para la modelización y pronóstico de series temporales interrumpidas, tomando como caso de estudio el flujo de pasajeros del Transporte Urbano de Rosario afectado por la pandemia de COVID-19. Ante un *shock* de tal magnitud, los modelos estadísticos tradicionales enfrentan dificultades para capturar cambios estructurales abruptos. El trabajo evalúa y compara el desempeño de modelos ARIMA, modelos de suavizado exponencial (ETS), métodos de intervención y enfoques contrafactuales, además de proponer una combinación de pronósticos (*Ensemble*).

Los resultados indican que, durante el periodo de recuperación (2021-2022), los modelos altamente adaptativos (ETS) y el método de combinación mostraron ventajas por sobre las estructuras rígidas de ARIMA, demostrando menores errores de predicción en términos de RMSE y MAE. Se concluye que, ante eventos disruptivos, la capacidad de ajuste local y la adaptabilidad de los modelos son criterios más determinantes para la precisión del pronóstico que el cumplimiento estricto de los supuestos clásicos de ruido blanco. Estos hallazgos aportan evidencia empírica sobre el desempeño de distintas estrategias de pronóstico en series temporales interrumpidas y constituyen una herramienta de apoyo para la toma de decisiones y la planificación del transporte urbano en contextos de elevada incertidumbre y cambios estructurales.

Palabras claves: Series Temporales, Interrupción, Transporte Urbano, COVID-19

1. Introducción

El análisis y pronóstico de series temporales constituyen herramientas fundamentales en diversas áreas aplicadas -como economía, salud, movilidad, transporte, energía, educación y políticas públicas- debido a su capacidad para describir la evolución de los fenómenos y anticipar escenarios futuros. Sin embargo, los métodos tradicionales suelen basarse en el supuesto de estabilidad de los patrones históricos y de continuidad estructural. Este supuesto puede resultar problemático cuando las series se ven afectadas por eventos disruptivos que alteran la regularidad de su comportamiento.

Los *shocks* exógenos -tales como pandemias, reformas regulatorias, cambios en los comportamientos sociales, interrupciones en infraestructuras (por ejemplo, la bajante extraordinaria del río Paraná entre 2019 y 2021, que restringió durante meses la capacidad de carga de los buques en los puertos del Gran Rosario) o eventos extraordinarios- generan alteraciones significativas en las series temporales. En muchos casos, estos eventos se manifiestan a través de quiebres de nivel, cambios en la tendencia y la estacionalidad, observaciones atípicas extremas y procesos de recuperación no lineales. La irrupción simultánea de alguno de estos fenómenos desafía los supuestos y la capacidad de adaptación de la mayoría de los modelos clásicos, dificultando la obtención de pronósticos precisos, especialmente cuando se busca comprender el comportamiento inmediato posterior a la disrupción y la trayectoria de recuperación.

Un caso particularmente relevante, tanto en Argentina como a nivel mundial, es la pandemia de COVID-19. Durante el año 2020, esta produjo una alteración abrupta en las series de movilidad y transporte urbano: el volumen de pasajeros transportados cayó a mínimos históricos debido a las restricciones de circulación, seguido de una recuperación lenta y heterogénea a medida que las restricciones se fueron flexibilizando. Estas características convierten a las series de transporte y movilidad en un contexto adecuado para el análisis de metodologías robustas para el tratamiento de series temporalmente interrumpidas.

Recientemente, Hyndman y Rostami-Tabar (2024) han sistematizado diversas estrategias para el tratamiento y pronóstico de series interrumpidas, incluyendo modelos altamente adaptativos, modelos de intervención, métodos contrafactuales y combinaciones (*ensembles*), planteando un marco conceptual que resulta particularmente relevante para series afectadas por *shocks* como los observados en el transporte urbano durante la pandemia.

En este contexto, la presente tesina propone evaluar el desempeño de distintas metodologías de pronóstico para series temporales interrumpidas mediante su aplicación a la serie mensual de pasajeros del Transporte Urbano de Pasajeros (TUP) de la ciudad de Rosario. A través de la comparación de estas estrategias en el periodo disruptivo y la etapa posterior, se busca generar evidencia empírica que contribuya a la comprensión de su comportamiento frente a cambios

estructurales abruptos y al análisis de series temporales en escenarios de alta incertidumbre.

2. Objetivos

2.1 Objetivo general

Evaluar, de manera comparativa, distintas metodologías de pronóstico aplicables a series temporales univariadas interrumpidas, mediante su aplicación a la serie de pasajeros del transporte urbano de Rosario, con el fin de analizar su desempeño predictivo en distintos momentos del ciclo disruptivo.

2.2 Objetivos específicos

- Realizar un análisis descriptivo detallado de la serie, identificando el periodo de interrupción y sus efectos sobre la tendencia y estacionalidad.
- Ajustar modelos ARIMA (*AutoRegressive Integrated Moving Average*) y SARIMA (*Seasonal AutoRegressive Integrated Moving Average*) como línea de base, evaluando su estabilidad en presencia de eventos disruptivos.
- Implementar modelos altamente adaptativos (ETS) y analizar su capacidad de ajuste durante la disrupción.
- Ajustar modelos de intervención (regresión con errores ARIMA), incorporando variables explicativas que representen el evento disruptivo.
- Implementar modelos contrafactuales:
 - Estableciendo el periodo disruptivo como faltante ("*set to missing*").
 - Reconstrucción del periodo mediante estimaciones de lo que podría haber sido ("*what might have been*").
- Explorar combinaciones de modelos (*ensembles*) y evaluar su impacto en el desempeño predictivo.
- Comparar todas las estrategias mediante métricas puntuales y probabilísticas (RMSE, MAE, MAPE y *Winkler Score*).
- Elaborar recomendaciones metodológicas para el uso de estas estrategias en series temporales afectadas por disrupciones similares.

3. Metodología

En esta sección se presentan diversas estrategias para manejar interrupciones en el pronóstico de series temporales. El tratamiento de interrupciones en series de tiempo constituye un problema complejo y multifacético, y la elección de la estrategia más adecuada depende de las características específicas de los datos y de la naturaleza de la interrupción. Por esta razón, en la presente tesina se adoptan múltiples estrategias en lugar de un único enfoque, con el fin de abordar de manera efectiva distintas situaciones y casos.

3.1 Conceptos básicos de series de tiempo

Una serie de tiempo es una secuencia de observaciones ordenadas de una variable objetivo a lo largo del tiempo en intervalos regulares (cada día, cada mes, cada año, etc.). La naturaleza intrínseca de las series temporales es que sus observaciones son dependientes o correlacionadas, y por lo tanto, el orden de las observaciones es importante. Por esta razón, los procedimientos basados en el supuesto de independencia no resultan aplicables, lo que requiere el uso de metodologías específicas para series temporales.

Formalmente, un proceso estocástico es un conjunto de variables aleatorias y_t donde el índice t toma valores en un cierto conjunto C . En el caso de las series temporales, este conjunto es ordenado y corresponde a los instantes temporales (días, meses, años, etc.). Para cada valor t del conjunto C , es decir, para cada instante temporal, está definida una variable aleatoria y_t , y los valores observados de las variables aleatorias en distintos instantes forman una serie temporal. Por lo tanto, una serie de tiempo de T datos, $(y_1, y_2, \dots, y_T)$, es una muestra de tamaño uno del vector de T variables aleatorias ordenadas en el tiempo correspondientes a los momentos $t = 1, \dots, T$, y la serie observada se considera una realización del proceso estocástico.

En el análisis de series temporales resulta esencial identificar los patrones que influyen en su comportamiento a lo largo del tiempo, ya que estos permiten comprender la dinámica de los datos y facilitan su adecuada modelización. Entre los principales componentes que pueden observarse en una serie temporal se destacan la tendencia, la estacionalidad, el componente cíclico y el componente aleatorio, los cuales se describen a continuación.

- Tendencia: esta componente refleja un crecimiento o decrecimiento en la serie a través del tiempo, no tiene que ser necesariamente lineal. A veces se refiere a la tendencia como un cambio de dirección, cuando se pasa de una tendencia creciente a una decreciente.
- Estacionalidad: es el comportamiento repetitivo de la serie en un periodo corto y conocido, esta componente está afectada por factores estacionales tales como el momento del año o el día de la semana entre otros.

- Ciclo: corresponde a oscilaciones de largo plazo que se manifiestan en torno a la tendencia, sin una periodicidad fija, y cuya duración suele extenderse por un periodo no inferior a dos años.
- Aleatorio: comprende las variaciones irregulares de la serie que no pueden ser atribuidas a la tendencia, la estacionalidad ni al componente cíclico. Dichas fluctuaciones responden, en general, a perturbaciones imprevisibles o a la influencia de factores externos no sistemáticos.

En el análisis de series temporales, es importante determinar si una serie es estacionaria o no lo es. Se dice que una serie es estacionaria en sentido débil si, para todo t :

$$1. E(y_t) = \mu_t = \mu \quad (1)$$

$$2. Var(y_t) = \sigma_t^2 = \sigma^2 \quad (2)$$

$$3. Cov(y_t, y_{t-k}) = \gamma_k \quad k = 0, \pm 1, \pm 2, \text{ etc} \quad (3)$$

Las dos primeras condiciones indican que la media y la varianza son constantes. La tercera, que la covarianza entre dos variables depende sólo de su separación.

Por otro lado, diremos que una serie es no estacionaria si la media, la varianza y la covarianza no son constantes a través del tiempo. Una forma de solucionar la no estacionariedad en media es tomando una cantidad adecuada de diferencias de la serie, es decir, si la serie $\{y_t\}$ es no estacionaria y tomamos una cantidad d de diferencias se obtiene una nueva serie $\{(1-B)^d y_t\}$ para algún entero $d \geq 1$, que es estacionaria. Para determinar la cantidad de diferenciaciones necesarias, puede recurrirse a la inspección de la función de autocorrelación o bien a una prueba de hipótesis, como por ejemplo, el test de Kwiatkowski-Phillips-Schmidt-Shin (KPSS). El mismo se emplea para verificar la hipótesis nula de que la serie es estacionaria. Por consiguiente, un p-valor inferior al nivel de significación adoptado (comúnmente 0,05) proporciona evidencia estadística para rechazar dicha hipótesis, indicando la necesidad de aplicar una o más diferenciaciones para estabilizar la media.

Sin embargo, un proceso puede ser estacionario en media pero no en varianza y covarianza. Por lo tanto, para corregir este problema es necesario aplicar la transformación de Box-Cox a la variable objetivo, definida como:

$$T(y_t) = \begin{cases} \frac{y_t^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0 \\ \ln(y_t) & \text{si } \lambda = 0 \end{cases} \quad (4)$$

3.1.1 Autocorrelación

La autocorrelación es una medida de asociación que mide la correlación entre una serie temporal y la misma serie en diferentes momentos. Es una herramienta fundamental en el

análisis de series ya que permite detectar no aleatoriedad, identificar dependencias temporales y validar modelos de series temporales (por ejemplo, *AR*, *ARMA*, entre otros).

3.1.1.1 Función de Autocorrelación

La Función de Autocorrelación (ACF, por sus siglas en inglés) es un recurso ampliamente utilizado en el análisis de series temporales, ya que permite cuantificar el grado de asociación lineal entre los valores de la serie y sus propios valores pasados a distintos rezagos. Formalmente, la autocorrelación correspondiente a un rezago k se define mediante la siguiente expresión:

$$\rho_k = \frac{Cov(y_t, y_{t+k})}{\sqrt{Var(y_t)}\sqrt{Var(y_{t+k})}} = \frac{\gamma_k}{\gamma_0} \quad (5)$$

donde ρ_k es el coeficiente de autocorrelación para el rezago k , y_t y y_{t+k} son los valores de la serie en los tiempos t y $t + k$ respectivamente, γ_k es la autocovarianza de rezago k y notar que $Var(y_t) = Var(y_{t+k}) = \gamma_0$.

El coeficiente ρ_k varía de -1 a 1. Si ρ_k está cerca de 1 indica que los valores de la serie están altamente correlacionados con los valores rezagados en k momentos. Si ρ_k está cerca de -1 indica que los valores de la serie están altamente correlacionados de forma negativa con los valores rezagados en k momentos. Por último, si ρ_k está cerca de 0 indica que no hay una correlación importante entre los valores de la serie para ese rezago.

3.1.1.2 Función de Autocorrelación Parcial

La Función de Autocorrelación Parcial (PACF, por sus siglas en inglés) permite medir la relación lineal directa entre una observación y su valor rezagado k , eliminando previamente el efecto de los rezagos intermedios $1, 2, \dots, k - 1$. A diferencia de la Función de Autocorrelación (ACF), que capta tanto efectos directos como indirectos entre los valores de la serie, la PACF aísla la contribución de cada rezago respecto de la de dichos rezagos intermedios, sin que ello suponga eliminar el efecto de los rezagos posteriores $k + 1, k + 2, \dots$, que continúan contribuyendo a la relación entre las observaciones. La expresión de la autocorrelación parcial correspondiente al rezago k resulta:

$$\phi_{kk} = Corr(y_t, y_{t+k} | y_{t+1}, y_{t+2}, \dots, y_{t+k-1}) \quad (6)$$

Esta función resulta especialmente útil en la etapa de identificación de modelos autorregresivos dentro de la metodología de Box-Jenkins, ya que un corte claro en la PACF suele indicar el posible orden p de un modelo $AR(p)$.

3.1.2 Pronósticos

Uno de los objetivos primordiales del análisis de series temporales es la obtención de pronósticos tanto puntuales como por intervalos de predicción, de la variable de interés a partir de los modelos ajustados. Formalmente, el pronóstico puntual a un horizonte l , con $l > 0$, se define como el valor esperado condicional de la variable futura dado el conjunto de información disponible hasta el instante T :

$$\hat{y}_{T+l|T} = E(y_{T+l} | y_T, y_{T-1}, \dots) \quad (7)$$

Además de los pronósticos puntuales, resulta de interés cuantificar la incertidumbre asociada a las predicciones mediante intervalos de predicción. Estos pueden construirse bajo supuestos distribucionales específicos, como la normalidad de los errores, o bien a partir de distribuciones predictivas obtenidas mediante simulación, permitiendo representar de manera más completa la variabilidad inherente al proceso generador de datos.

3.2 ARIMA/SARIMA

Los modelos ARIMA representan uno de los enfoques más utilizados y consolidados para el análisis y pronóstico de series temporales univariadas. Estos están compuestos por tres componentes esenciales: la parte autorregresiva (AR), el término integrado o de diferenciación (I) y la parte promedio móvil (MA). El modelo general se expresa como:

$$\phi_p(B) \nabla^d y_t = \theta_q(B) \varepsilon_t \quad (8)$$

donde y_t representa el valor observado, $\phi_p(B) = (1 - \phi_1 B - \dots - \phi_p B^p)$ es el operador AR regular de orden p , $\nabla^d = (1 - B)^d$ representa las diferencias regulares y $\theta_q(B) = (1 - \theta_1 B - \dots - \theta_q B^q)$ es el operador promedio móvil regular de orden q . Adicionalmente, se asume que el término de error ε_t constituye un proceso ruido blanco gaussiano, es decir, $\varepsilon_t \underset{iid}{\sim} \mathcal{N}(0, \sigma_\varepsilon^2)$.

La componente autorregresiva modela la dependencia entre el valor actual de la serie y sus valores pasados, por lo que un proceso autorregresivo de orden p puede escribirse como:

$$\phi_p(B) y_t = \varepsilon_t \quad (9)$$

Este enfoque es análogo a una regresión lineal múltiple, con la particularidad de que los predictores corresponden a valores rezagados de y_t . Este enfoque se denomina modelo autorregresivo $AR(p)$, que se formula, en general, para series estacionarias y exige

determinadas restricciones sobre sus parámetros. Por definición, un proceso $AR(p)$ es siempre invertible —esto es, admite una representación autorregresiva de orden infinito, propiedad inmediata en su caso por estar ya escrito en dicha forma—, pero para que sea estacionario es necesario que las raíces de $\phi_p(B) = 0$ caigan fuera del círculo unitario.

La componente promedio móvil refleja la dependencia entre el valor actual de la serie y los errores de pronósticos previos, por lo que un proceso promedio móvil de orden q se lo puede escribir como:

$$y_t = \theta_q(B)\varepsilon_t \quad (10)$$

Por definición se tiene que este proceso es siempre estacionario, pero para que sea invertible, condición deseable, es necesario que las raíces de $\theta_q(B) = 0$ caigan fuera del círculo unitario.

Así, la incorporación conjunta de estas componentes y la utilización de un orden apropiado de diferenciación en la parte regular permiten capturar estructuras sistemáticas complejas, con el propósito de obtener un ajuste adecuado del modelo.

Sin embargo, los modelos ARIMA no incorporan la estacionalidad de manera explícita, es por ello que, para series con estacionalidad marcada, como ocurre con series mensuales o trimestrales, se emplean los modelos SARIMA:

$$\Phi_P(B^s)\phi_p(B)\nabla_s^D\nabla^d y_t = \theta_q(B)\Theta_Q(B^s)\varepsilon_t \quad (11)$$

donde y_t representa el valor observado, $\Phi_P(B^s) = (1 - \Phi_1 B^s - \dots - \Phi_P B^{sP})$ es el operador AR estacional de orden P , $\nabla_s^D = (1 - B^s)^D$ representa las diferencias estacionales, $\Theta_Q(B^s) = (1 - \Theta_1 B^s - \dots - \Theta_Q B^{sQ})$ es el operador promedio móvil estacional de orden Q y ε_t es un proceso ruido blanco gaussiano.

Con el objetivo de seleccionar la especificación más adecuada, se utilizará la función `ARIMA()` del paquete `fable` de R, que permite realizar una selección automática del mejor modelo basándose en el algoritmo de Hyndman-Khandakar.

Dicho algoritmo implementa un procedimiento automatizado para la identificación del modelo ARIMA más adecuado. En primer lugar, evalúa la necesidad de diferenciación mediante la aplicación de tests de raíz unitaria, tales como el test de KPSS.

Posteriormente, el algoritmo realiza una búsqueda en el espacio de posibles modelos, combinando distintos órdenes de las componentes autorregresivas y de promedio móvil, tanto regulares como estacionales. Esta exploración se lleva a cabo mediante un enfoque iterativo.

En cada iteración, los modelos candidatos son estimados mediante máxima verosimilitud y comparados utilizando el criterio de información corregido de Akaike ($AICc$). Finalmente, se

selecciona aquel modelo que minimiza dicho criterio.




Figura 1: Ejemplo ilustrativo del proceso iterativo de búsqueda de los parámetros del algoritmo de Hyndman-Khandakar.

La Figura 1 ilustra este procedimiento sobre el plano de órdenes regulares (p, q) , una vez fijado el orden de diferenciación d a través del test de KPSS. El algoritmo no evalúa la totalidad de las combinaciones posibles —representadas por los puntos grises—, sino que recorre el espacio de manera dirigida. En el primer paso se estiman cuatro modelos iniciales: $ARIMA(0, d, 0)$, $ARIMA(1, d, 0)$, $ARIMA(0, d, 1)$ y $ARIMA(2, d, 2)$. El que arroja el menor AIC_c , señalado con un círculo, se adopta como modelo de referencia. En cada iteración subsiguiente se estiman las variaciones que modifican p y/o q en ± 1 respecto del modelo vigente, y si alguna de ellas mejora el criterio, pasa a ocupar el lugar de referencia y define el centro de la búsqueda siguiente. Así, el recorrido avanza desde el modelo inicial hacia órdenes crecientes paso 2 y 3 hasta que, en el paso 4, ninguna de las variaciones exploradas logra reducir el AIC_c y el procedimiento se detiene, quedando seleccionado el último modelo circundado.

Si bien los modelos ARIMA y SARIMA constituyen un punto de partida indispensable, presentan limitaciones importantes cuando la serie contiene eventos disruptivos. Bajo estas

circunstancias, los parámetros estimados a partir de datos previos a la interrupción pueden no reflejar adecuadamente el comportamiento posterior. Asimismo, la adaptación del modelo al patrón estacional posterior puede ser lenta o inestable.

Por estas razones, en este trabajo los modelos ARIMA y SARIMA se consideran como modelos de referencia (*baseline*) para la comparación con enfoques diseñados explícitamente para capturar interrupciones, tal como proponen Hyndman y Rostami-Tabar (2024).

3.3 Modelos altamente adaptativos (ETS)

Los modelos de suavizado exponencial, o modelos ETS (*Error–Trend–Seasonality*), constituyen una familia alternativa caracterizada por su capacidad de adaptarse rápidamente a cambios recientes en la estructura de la serie. Estos modelos pueden ajustarse a la interrupción a medida que ocurre. Por lo tanto, suelen aproximarse relativamente bien al proceso de generación de datos. Su formulación se basa en la actualización recursiva de componentes no observados (error, tendencia y estacionalidad), utilizando ponderaciones decrecientes para las observaciones pasadas.

La estructura general del modelo se compone de:

- una componente de error (E) que describe la variabilidad de los datos que no se puede explicar por la tendencia ni por la estacionalidad.
- una componente de tendencia (T) que explica la dirección que sigue la serie temporal, puede ser creciente, decreciente o nula.
- una componente de estacionalidad (S) que se refiere al comportamiento repetitivo en intervalos regulares específicos que tiene la serie temporal.

Estos tres componentes pueden introducirse al modelo de forma aditiva (A), multiplicativa (M), o en el caso de la tendencia y estacionalidad no incluirse (N). Por ejemplo, un modelo ETS(A,N,M) indica que el error ingresa de forma aditiva, la tendencia no se incluye y la estacionalidad ingresa de forma multiplicativa.

Entre sus principales características, se destaca su simplicidad de implementación y rapidez computacional. Además, no requiere modelar explícitamente la interrupción, por lo que el modelo puede utilizarse para realizar pronósticos incluso si se desconoce el momento o el efecto de la interrupción.

A continuación se presentan algunos de los ejemplos más conocidos de modelos ETS.

Suavizado Exponencial Simple (SES) - ETS(A,N,N)

El método de Suavizado Exponencial Simple resulta apropiado para la generación de

pronósticos en series que no presentan tendencia ni estacionalidad definida. Los pronósticos se calculan mediante promedios ponderados de las observaciones pasadas, donde los pesos decrecen de manera exponencial conforme las observaciones se alejan en el tiempo, asignándole menor peso a los datos más antiguos. La expresión de la generación de pronósticos resulta:

$$\hat{y}_{t+1|t} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \dots + \alpha(1 - \alpha)^{t-1}y_1 \quad (12)$$

donde $0 < \alpha < 1$.

Una forma alternativa de representar el modelo es con la forma de componentes, para el suavizado exponencial simple, la única componente que se incluye es el nivel, denotado como ℓ_t . Estas representaciones de los métodos de suavizado exponencial comprenden una ecuación de pronóstico y una ecuación de suavizado para cada uno de los componentes incluidos en el método. La forma de componentes del suavizado exponencial simple viene dada por:

- Ecuación de pronóstico: $\hat{y}_{t+h|t} = \ell_t$
- Ecuación de suavizado: $\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$

donde ℓ_t es el nivel (o el valor suavizado) de la serie en el tiempo t . Estableciendo $h = 1$, se obtienen los valores ajustados, mientras que al establecer $t = T$, se obtienen los pronósticos reales, más allá de los datos de entrenamiento.

Ahora bien, la ecuación de suavizado puede reorganizarse para obtener una representación conocida como forma de “corrección de error”. Partiendo de:

$$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1} \quad (13)$$

se obtiene:

$$\ell_t = \ell_{t-1} + \alpha(y_t - \ell_{t-1}) = \ell_{t-1} + \alpha\varepsilon_t \quad (14)$$

donde $\varepsilon_t = y_t - \ell_{t-1} = y_t - \hat{y}_t$ es el residuo en el tiempo t .

Para que esto se convierta en un modelo totalmente especificado es necesario indicar los supuestos distribucionales de los errores, los cuales son: $\varepsilon_t \underset{iid}{\sim} \mathcal{N}(0, \sigma_\varepsilon^2)$ y por lo tanto, el modelo puede escribirse como:

$$y_t = \ell_{t-1} + \varepsilon_t \quad (15)$$

$$\ell_t = \ell_{t-1} + \alpha\varepsilon_t \quad (16)$$

Con respecto a la estimación de los parámetros, una opción puede ser elegir los valores de

los parámetros de forma subjetiva (o en base a la experiencia previa). Sin embargo, una forma más fiable y objetiva de obtener valores para los parámetros desconocidos es estimarlos a partir de los datos observados utilizando algún método de estimación, como puede ser mediante la minimización de la suma de cuadrados de los errores (SCE).

Método lineal de Holt - ETS(A,A,N)

El método lineal de Holt constituye una extensión del Suavizado exponencial simple, que permite pronosticar series temporales que presentan tendencia. Éste involucra una ecuación de pronóstico y dos ecuaciones de suavizado (una para el nivel y una para la tendencia):

- Ecuación de pronóstico: $\hat{y}_{t+h|t} = \ell_t + hb_t$
- Ecuación de nivel: $\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$
- Ecuación de tendencia: $b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$

donde ℓ_t denota el nivel estimado de la serie en el tiempo t , b_t representa una estimación de la tendencia (pendiente) de la serie en el tiempo t , α es el parámetro de suavizado para el nivel, $0 \leq \alpha \leq 1$, y β^* es el parámetro de suavizado para la tendencia, $0 \leq \beta^* \leq 1$.

De forma análoga al Suavizado exponencial simple, la ecuación de nivel puede interpretarse como un promedio ponderado entre la observación actual y_t y el pronóstico de un paso adelante obtenido en el tiempo anterior ($\ell_{t-1} + b_{t-1}$). Por otro lado, la ecuación de tendencia establece que b_t es un promedio ponderado entre la variación estimada del nivel ($\ell_t - \ell_{t-1}$) y la estimación previa de la tendencia b_{t-1} .

En este modelo, la función de pronóstico deja de ser constante y pasa a ser lineal en el horizonte de predicción. Es decir, el pronóstico a h pasos se obtiene sumando al último nivel estimado ℓ_t el producto entre h y la última estimación de la tendencia b_t . En consecuencia, los pronósticos resultan ser una función lineal creciente (o decreciente) en función del horizonte h .

Para este modelo se considera que $\varepsilon_t = y_t - (\ell_{t-1} + b_{t-1})$, $\varepsilon_t \stackrel{iid}{\sim} \mathcal{N}(0, \sigma_\varepsilon^2)$ y siguiendo los pasos de la especificación anterior se obtiene:

$$y_t = \ell_{t-1} + b_{t-1} + \varepsilon_t \quad (17)$$

$$\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t \quad (18)$$

$$b_t = b_{t-1} + \alpha \beta^* \varepsilon_t \quad (19)$$

Método aditivo de Holt-Winters - ETS(A,A,A)

El método aditivo de Holt-Winters extiende el método lineal de Holt con el objetivo de

incorporar explícitamente la estacionalidad en el pronóstico. Este método se compone de una ecuación de pronóstico y tres ecuaciones de suavizado (una para el nivel ℓ_t , otra para la tendencia b_t y la última para la estacionalidad s_t). A cada una de estas ecuaciones le corresponden los parámetros de suavizado α , β^* y γ , respectivamente.

- Ecuación de pronóstico: $\hat{y}_{t+h|t} = \ell_t + hb_t + s_{t+h-m(k+1)}$
- Ecuación de nivel: $\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$
- Ecuación de tendencia: $b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$
- Ecuación de estacionalidad: $s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$

donde k es la parte entera de $\frac{h-1}{m}$, lo que garantiza que los índices estacionales utilizados en el pronóstico provengan del último año de la muestra y m representa el periodo estacional.

Aquí, la ecuación de nivel representa un promedio ponderado entre la observación desestacionalizada ($y_t - s_{t-m}$) y el pronóstico no estacional correspondiente al periodo t , dado por $(\ell_{t-1} + b_{t-1})$. La ecuación de tendencia coincide con el método lineal de Holt. Por su parte, la ecuación estacional expresa un promedio ponderado entre el índice estacional actual, $(y_t - \ell_{t-1} - b_{t-1})$, y el índice correspondiente a la misma estación del ciclo anterior.

Para este modelo se considera que $\varepsilon_t = y_t - (\ell_{t-1} + b_{t-1} + s_{t-m})$, $\varepsilon_t \underset{iid}{\sim} \mathcal{N}(0, \sigma_\varepsilon^2)$ y siguiendo los pasos de la especificación anterior se obtiene:

$$y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t \quad (20)$$

$$\ell_t = \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t \quad (21)$$

$$b_t = b_{t-1} + \alpha\beta^*\varepsilon_t \quad (22)$$

$$s_t = s_{t-m} + \gamma\varepsilon_t \quad (23)$$

Los modelos presentados previamente permiten capturar distintas configuraciones estructurales de la serie, tales como nivel, tendencia y estacionalidad. Cabe destacar que existen múltiples combinaciones posibles dependiendo de como ingresa cada componente al modelo, ya sea de forma aditiva, multiplicativa o sin incluirse en el modelo.

Con el fin de determinar la especificación más adecuada se utilizará la función $ETS()$ del paquete `fable` de R, que permite realizar una selección automática, identificando aquel modelo que minimice el/los criterio/s de información AIC_c , AIC o BIC .

Sin embargo, tal como señalan Hyndman y Rostami-Tabar (2024), los modelos ETS presentan limitaciones frente a *shocks* abruptos. En particular, requieren un periodo de adaptación para

que sus parámetros reflejen adecuadamente la nueva dinámica de la serie, lo que puede generar pronósticos más inestables durante y después de la interrupción. No obstante, su capacidad para ajustarse rápidamente a los cambios observados y su simplicidad de implementación los convierten en una excelente alternativa dentro del conjunto de metodologías consideradas para el análisis de series temporales interrumpidas.

3.4 Modelos de intervención (Regresión Dinámica con errores ARIMA)

Los modelos de intervención, también conocidos como modelos de regresión dinámica con errores ARIMA, están diseñados para describir y cuantificar el impacto de un evento externo en una serie temporal. Su propósito es identificar cómo, y en qué magnitud, se modifican los valores de la serie a partir de la ocurrencia de un hecho exógeno, permitiendo distinguir entre la evolución “natural” del proceso y los efectos atribuibles a dicho evento.

La intervención puede estar asociada a la implementación de una política pública, un programa o la ocurrencia de un evento disruptivo, como fue el caso de la pandemia de COVID-19. En tales contextos, la serie temporal puede experimentar quiebres estructurales que no pueden ser adecuadamente explicados mediante modelos de series temporales univariados tradicionales, lo cual justifica la incorporación explícita de variables que representen el evento en cuestión.

El enfoque clásico de intervención fue introducido por Box y Tiao (1975) y combina:

1. un modelo de regresión, que incorpora variables explicativas para representar el efecto del *shock*, y
2. un modelo ARIMA para los errores, que captura la dependencia temporal residual.

La estructura general se expresa como:

$$y_t = \beta_0 + \beta_1 \cdot x_{1,t} + \beta_2 \cdot x_{2,t} + \cdots + \beta_k \cdot x_{k,t} + \eta_t \quad (24)$$

$$\phi_p(B)\nabla^d\eta_t = \theta_q(B)\varepsilon_t \quad (25)$$

donde η_t representa el término de error del modelo de regresión y ε_t representa el término de error del modelo ARIMA.

Las variables de intervención pueden representar:

- cambios permanentes en la estructura,
- impactos transitorios,

- procesos de lenta recuperación.

La principal ventaja de estos modelos es que permiten incorporar explícitamente la estructura causal del evento y pronosticar interrupciones futuras similares. No obstante, diferenciar entre una verdadera interrupción y un factor determinante más general como un cambio tendencial, puede introducir cierto grado de subjetividad en el análisis.

En el marco conceptual de Hyndman y Rostami-Tabar (2024), los modelos de intervención constituyen la estrategia “estructural”, en la cual la interrupción se modela directamente como parte del proceso generador de datos.

3.5 Métodos contrafactuales

Los métodos contrafactuales abordan el problema desde una perspectiva distinta: en lugar de intentar modelar directamente el efecto del *shock*, se orientan a reconstruir cómo habría evolucionado la serie en ausencia del evento disruptivo. Esto permite generar pronósticos menos influenciados por valores atípicos y evaluar escenarios alternativos.

3.5.1 Establecer como faltante (*set to missing*)

La técnica “*Set to Missing*” consiste en identificar el periodo de interrupción en la serie temporal y marcar esas observaciones como valores perdidos, para luego ajustar el modelo sólo con los datos disponibles fuera del periodo interrumpido. De este modo, el modelo no utiliza información contaminada por la interrupción y genera pronósticos que representan lo que habría ocurrido sin el evento disruptivo. En este trabajo, los modelos ajustados bajo este enfoque corresponden a modelos ARIMA/SARIMA, la diferencia respecto de la primera estrategia está en qué datos se consideran al momento del ajuste.

Cabe destacar que los pronósticos generados para el periodo de interrupción no serán precisos, pero pueden interpretarse como escenarios contrafactuales. Por otro lado, los pronósticos posteriores a la interrupción tienden a ser más estables, dado que no se ven afectados por observaciones atípicas o ruidosas.

A pesar de que muchos modelos de series de tiempo tienen problemas con los datos faltantes, algunos enfoques pueden tratarlos adecuadamente. Wu, Chang y Lee (2015) sugieren una estrategia de pronósticos basados en LSSVM (*Least Squares Support Vector Machine*) que fue particularmente diseñado para trabajar con series temporales con datos faltantes.

La incorporación de valores faltantes incrementa la incertidumbre del modelo, dando lugar a intervalos de predicción más amplios. Esta característica señalada por Hyndman y Rostami-Tabar (2024), puede resultar beneficiosa desde una perspectiva interpretativa, ya que refleja de

manera realista la falta de información confiable durante los periodos disruptivos.

3.5.2 Lo que podría haber ocurrido (*what might have been*)

Este enfoque reconstruye el periodo de interrupción utilizando únicamente información previa al evento disruptivo, simulando el comportamiento que probablemente habría tenido la serie temporal si la interrupción no hubiese ocurrido. La idea consiste en reemplazar las observaciones distorsionadas por el evento disruptivo por valores estimados que reflejen la dinámica histórica del proceso antes de la interrupción. Las estrategias para obtener estas estimaciones son dos, y su aplicación es alternativa:

- **Enfrique basado en modelos.** Utilizar los datos del periodo pre-disruptivo para estimar un modelo (ARIMA, ETS, etc.) y obtener a partir de él las observaciones estimadas durante el período disruptivo.
- **Enfrique basado en medidas resumen.** Utilizar los datos del periodo pre-disruptivo para estimar las observaciones del periodo disruptivo mediante alguna medida resumen (media, mediana, entre otras).

Una vez obtenidas estas estimaciones, los valores reconstruidos se incorporan a la serie y se ajusta un modelo sobre el conjunto completo de datos, permitiendo así realizar pronósticos posteriores a la interrupción con mayor estabilidad. Los modelos utilizados en este enfoque son ARIMA/SARIMA la diferencia con respecto a *set to missing* está en que en este enfoque los datos no se ignoran, sino que se reconstruye el periodo.

Sin embargo, es importante notar que los valores estimados durante la interrupción no constituyen pronósticos genuinos en sentido estricto, ya que se habrá utilizado información futura para calcular los datos ajustados durante la interrupción. No obstante, los pronósticos posteriores a la interrupción sí constituyen pronósticos genuinos y deberían presentar diferencias mínimas respecto de los obtenidos mediante la estrategia anterior (*set to missing*).

3.6 Métodos de combinación (*ensemble*)

Los métodos de combinación, o *ensembles*, consisten en integrar múltiples modelos para producir un pronóstico final que aproveche las fortalezas de cada uno. Su fundamento teórico radica en que distintos modelos capturan fuentes de información parciales y no redundantes que, al combinarse, se complementan entre sí.

Hendry y Clements (2004) demostraron que el *ensemble* puede ser visto como una aplicación del estimador de *James-Stein*, donde el valor futuro desconocido funciona como un meta-parámetro cuya estimación mejora al promediar distintas fuentes de información parcial.

En el contexto de series interrumpidas, Hyndman y Rostami-Tabar (2024) destacan que los *ensembles* son especialmente valiosos porque permiten combinar:

- modelos tradicionales (ARIMA/SARIMA),
- modelos altamente adaptativos (ETS),
- modelos de intervención,
- métodos contrafactuales.

Esta integración permite reducir la inestabilidad que presentan algunos enfoques en la fase del *shock* o en la recuperación temprana.

La forma de *ensemble* utilizada en esta tesina será la combinación lineal simple, expresada como:

$$\tilde{y}_{T+h|T} = \sum_{i=1}^N w_{T+h|T,i} \cdot \hat{y}_{T+h|T,i} \quad (26)$$

donde $\tilde{y}_{T+h|T}$ es el pronóstico del ensemble h pasos hacia adelante, $w_{T+h|T,i}$ el peso asignado al i -ésimo modelo de pronóstico, el cual es el mismo para todos los modelos y cuya suma da 1, y $\hat{y}_{T+h|T,i}$ es el i -ésimo pronóstico del modelo utilizado.

Para la construcción de los intervalos de predicción en esta estrategia, se realiza una mezcla de distribuciones de los N métodos de pronóstico individuales utilizados estimando los pesos que se le asigna a cada método, esta estrategia se la conoce como “*linear opinion pool*”. Formalmente, se la define como:

$$\tilde{F}(y_{T+h}|I_T) = \sum_{i=1}^N w_{T+h|T,i} \cdot F_i(y_{T+h}|I_T) \quad (27)$$

donde $\tilde{F}(y_{T+h}|I_T)$ es la función de distribución combinada para la variable y en el instante $T + h$, usando la información disponible hasta T , $w_{T+h|T,i}$ el peso asignado al i -ésimo modelo de pronóstico, el cual es el mismo para todos los modelos y cuya suma da 1, y $F_i(y_{T+h}|I_T)$ es la función de distribución para la variable y en el instante $T + h$, usando la información disponible hasta T , del i -ésimo modelo de pronóstico.

Una vez obtenida la distribución predictiva combinada, los intervalos de predicción pueden interpretarse, de manera general, mediante la expresión:

$$\tilde{y}_{T+h|T} \pm c \cdot \tilde{\sigma}_h \quad (28)$$

donde c es el cuantil de la distribución utilizada que depende de la probabilidad de cobertura deseada para calcular el intervalo de predicción y $\tilde{\sigma}_h$ representa una estimación del desvío

estándar de la distribución predictiva combinada h pasos hacia adelante. No obstante, en esta tesina los intervalos de predicción no se calculan bajo un supuesto paramétrico de normalidad, sino a partir de los cuantiles empíricos de la distribución predictiva obtenida mediante simulaciones de los distintos modelos que integran el *ensemble*.

Esta combinación lineal aporta robustez, atenúa los errores específicos de cada enfoque y suele superar a los métodos individuales, aunque puede resultar inadecuada cuando los objetivos de los componentes difieren, como por ejemplo, predecir lo que ocurrió frente a lo que podría haber ocurrido. Esto se debe a que la ganancia del *ensemble* proviene de promediar errores en torno a una misma cantidad de interés, condición que deja de cumplirse cuando cada componente responde a una pregunta distinta. Un modelo factual estima la trayectoria efectivamente observada, mientras que uno contrafactual proyecta el comportamiento que la serie habría tenido en ausencia del *shock*; al promediarlos se obtiene una trayectoria intermedia que no representa ninguno de los dos escenarios.

De todas formas, diversos estudios han demostrado que a pesar de su simplicidad, el promedio simple suele ser competitivo e incluso superar combinaciones más complejas, especialmente cuando los modelos individuales poseen desempeños heterogéneos ante las interrupciones.

3.7 Métricas de evaluación

Con el fin de comparar el desempeño de los modelos propuestos, es necesario definir diversas métricas de evaluación. Estas métricas permiten analizar tanto la capacidad de ajuste como el desempeño predictivo puntual y la calidad de los intervalos de predicción de los distintos métodos.

3.7.1 Raíz del error cuadrático medio (RMSE)

Es una medida directa del error de predicción en las mismas unidades que la variable respuesta, representa la raíz cuadrada del promedio de las diferencias al cuadrado entre los valores observados y los valores predichos. Valores bajos indican un mejor desempeño predictivo. Su expresión resulta:

$$RMSE(\hat{y}, y) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (29)$$

donde y_i es el i -ésimo valor real, $\hat{y}_i$ es el i -ésimo valor pronosticado y n es la cantidad de observaciones predichas.

3.7.2 Error absoluto medio (MAE)

Es una métrica que cuantifica la magnitud promedio de los errores en un conjunto de predicciones en las mismas unidades que la variable respuesta, sin considerar su dirección. Al centrarse únicamente en el tamaño de los errores, ayuda a identificar qué tan lejos están las predicciones de los resultados reales. Valores pequeños indican buenos resultados. Su expresión resulta:

$$MAE(\hat{y}, y) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (30)$$

donde y_i es el i -ésimo valor real, $\hat{y}_i$ es el i -ésimo valor pronosticado y n es la cantidad de observaciones.

3.7.3 Error porcentual absoluto medio (MAPE)

Al igual que el MAE, el MAPE es una métrica de precisión que mide la desviación promedio de un valor predicho respecto al valor observado, con la ventaja de ser más fácil de interpretar

al no tener en cuenta la escala de medición. Menores valores de esta métrica representan una mayor exactitud en las predicciones. Su expresión resulta:

$$MAPE(\hat{y}, y) = \left(\frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \right) \cdot 100\% \quad (31)$$

donde y_i es el i -ésimo valor real, $\hat{y}_i$ es el i -ésimo valor pronosticado y n es la cantidad de predicciones.

3.7.4 Puntuación de Winkler (*Winkler Score*)

Es una métrica que evalúa el intervalo de predicción de los modelos ajustados, si la observación cae dentro del intervalo de predicción su valor resulta en la amplitud del intervalo, mientras que si la observación cae fuera del intervalo de predicción a dicha amplitud se le sumará un término de penalización que es proporcional a cuán lejos la observación cae del intervalo. Una puntuación baja del *score* refleja intervalos más estrechos y con mejor cobertura. Su expresión resulta:

$$W_{\alpha,t} = \begin{cases} (u_{\alpha,t} - l_{\alpha,t}) + \frac{2}{\alpha} (l_{\alpha,t} - y_t) & \text{si } y_t < l_{\alpha,t} \\ (u_{\alpha,t} - l_{\alpha,t}) & \text{si } l_{\alpha,t} \leq y_t \leq u_{\alpha,t} \\ (u_{\alpha,t} - l_{\alpha,t}) + \frac{2}{\alpha} (y_t - u_{\alpha,t}) & \text{si } y_t > u_{\alpha,t} \end{cases} \quad (32)$$

donde y_t es el valor observado en el tiempo t , $u_{\alpha,t}$ es el límite superior del intervalo de predicción en el tiempo t , $l_{\alpha,t}$ es el límite inferior del intervalo de predicción en el tiempo t y $1 - \alpha$ es el nivel de confianza establecido.

Para la obtención de la puntuación global, se calcula el promedio de las h puntuaciones obtenidas, cuya expresión resulta:

$$W_{\alpha} = \frac{1}{h} \cdot \sum_{t=1}^h W_{\alpha,t} \quad (33)$$

3.7.5 Ajuste y evaluación de los modelos

Dado que los eventos disruptivos producen cambios abruptos en la estructura temporal, el procedimiento de ajuste y evaluación de los modelos se llevará a cabo en base a un esquema con ventana expansiva (*expanding window*), el cual constituye un caso particular del enfoque de *rolling forecasting origin* utilizado en la literatura de series temporales (Hyndman y Athanasopoulos, 2021).

Bajo este enfoque, el procedimiento consiste en definir un origen de pronóstico, es decir, el periodo hasta el cual se ajustarán los modelos, y un horizonte de pronóstico de 12 meses, considerando el caso de series mensuales. Se seleccionó este horizonte de pronóstico debido a que permite capturar un ciclo estacional completo de la serie. A partir de ello, en cada ventana se ajustan los distintos modelos utilizando toda la información disponible hasta el origen definido, para luego generar los pronósticos correspondientes. Posteriormente, el origen se desplaza 12 meses hacia adelante y el proceso se repite de manera iterativa, permitiendo obtener pronósticos de todos los modelos en cada una de las ventanas consideradas. La siguiente figura presenta una representación ilustrativa de este procedimiento.




Figura 2: Proceso ilustrativo de ajuste y evaluación de los modelos

4. Aplicación

La aplicación empírica se desarrolla sobre una serie mensual de movilidad urbana correspondiente al total de pasajeros transportados por el sistema de Transporte Urbano de Pasajeros (TUP) de la ciudad de Rosario. El estudio abarca el periodo comprendido entre enero de 2006 y diciembre de 2024, y se llevó a cabo utilizando el lenguaje de programación R.

Dicha serie presenta características que la convierten en un caso de estudio adecuado para evaluar y comparar metodologías de pronóstico diseñadas para series interrumpidas. En particular, permite analizar la capacidad de los distintos enfoques para adaptarse a cambios estructurales abruptos y generar pronósticos confiables en contextos de alta incertidumbre.

El procedimiento se estructuró de acuerdo con los siguientes pasos:

- **Preprocesamiento de los datos:** Se realizó un proceso riguroso de limpieza y transformación de los datos, utilizando herramientas provistas por los paquetes del ecosistema *tidyverse*.
- **Análisis de las características de la serie:** Se examinaron las propiedades intrínsecas de la serie, incluyendo la identificación de tendencia, estacionalidad y periodo donde ocurre la disrupción, a través de herramientas visuales implementadas con la librería *ggplot2*.
- **Modelización y análisis del *shock* pandémico (2020), de la etapa de recuperación (2021-2022) y estabilización (2023–2024):** Se ajustaron los modelos previamente seleccionados para capturar y pronosticar esta transición, empleando las librerías del paquete *fpp3*.
- **Evaluación comparada de pronósticos:** Se evaluó el desempeño de los diversos enfoques tanto durante la disrupción como en el periodo posterior, a través de métricas puntuales y probabilísticas, utilizando las librerías del paquete *fpp3*.

El propósito de esta aplicación es, por un lado, ofrecer un análisis riguroso de la evolución de la movilidad urbana en la ciudad de Rosario a lo largo de casi dos décadas y, por otro, generar evidencia empírica sólida que permita identificar qué estrategias de modelización resultan más adecuadas para el tratamiento de series temporales interrumpidas, caracterizadas por *shocks* abruptos y procesos de recuperación graduales.

4.1 Análisis descriptivo

La serie en estudio corresponde al número de pasajeros transportados de forma mensual por el sistema de Transporte Urbano de Pasajeros (TUP) en la ciudad de Rosario.

Se define como “pasajeros transportados” al volumen total de viajes abonados mediante el sistema de cancelación, independientemente de la existencia de beneficios, subsidios o

gratuidades. Esta definición permite trabajar con una medida homogénea y comparable a lo largo del tiempo, representativa del volumen real de demanda del sistema.

En la Figura 3 se observa la evolución temporal de la serie para el periodo comprendido entre enero de 2006 y diciembre de 2024. En términos generales, la serie presenta un comportamiento estable hasta 2019, con fluctuaciones moderadas alrededor de un nivel elevado de utilización. No obstante, resulta evidente la presencia de un conjunto de observaciones atípicas durante los años 2020 y 2021, las cuales constituyen un quiebre significativo en la dinámica de la demanda.

Estas observaciones atípicas se explican por las restricciones sanitarias impuestas en el contexto de la pandemia de COVID-19, las cuales afectaron de manera directa la movilidad urbana. Como consecuencia, se registra una caída abrupta en el número de pasajeros transportados, seguida de un proceso de recuperación posterior. No obstante, dicha recuperación presenta un comportamiento no lineal y, en general, no alcanza los niveles observados en el periodo prepandemia, lo que sugiere la posible existencia de cambios estructurales persistentes en la demanda del servicio.

Por otro lado, la Figura 4 permite analizar el comportamiento estacional de la serie. Se observa una estacionalidad anual bien definida, con caídas sistemáticas en los meses asociados a periodos vacacionales, particularmente en diciembre, enero y febrero, así como en julio. Estos descensos se encuentran vinculados a la reducción de la actividad educativa y laboral, lo cual impacta directamente en la demanda del transporte público.

Asimismo, durante los meses restantes se observan niveles relativamente más elevados y estables, lo que refuerza la existencia de un patrón estacional recurrente en la serie. Este comportamiento se mantiene de manera consistente en el periodo previo a la pandemia, aunque se ve parcialmente alterado durante los años 2020 y 2021 como consecuencia del evento disruptivo.

En relación con la tendencia de largo plazo, se observa una leve tendencia decreciente a lo largo de los años. Si bien parte de esta tendencia puede explicarse por el impacto de la pandemia, también podrían intervenir otros factores estructurales, tales como cambios en los hábitos de movilidad, la incorporación de medios de transporte alternativos o transformaciones en la dinámica urbana.




Figura 3: Pasajeros transportados por el sistema de Transporte Urbano de Pasajeros en la ciudad de Rosario. Periodo 01/2006-12/2024.




Figura 4: Cantidad de pasajeros transportados por el sistema de Transporte Urbano de Pasajeros en la ciudad de Rosario por año.

Con respecto al análisis de dispersión, la Figura 5 muestra la distribución anual de los pasajeros transportados. En ella se puede identificar una leve disminución en la media a lo largo del tiempo, así como una variabilidad que no parece ser constante entre años. Este comportamiento sugiere la presencia de heterocedasticidad, es decir, cambios en la variabilidad de la serie a lo largo del tiempo.

Estos patrones constituyen un indicio de que la serie no es estacionaria, tanto en media como en varianza. En particular, la presencia de una tendencia y de cambios en la dispersión refuerza la necesidad de aplicar transformaciones y/o diferenciaciones para lograr una representación adecuada del proceso.




Figura 5: Distribución anual de pasajeros transportados por el sistema de Transporte Urbano de Pasajeros en la ciudad de Rosario.

Con el objetivo de estabilizar la varianza de la serie, se consideró la aplicación de una transformación de Box-Cox. Inicialmente, se estimó el parámetro λ utilizando el método “Guerrero” sobre la totalidad de las observaciones disponibles, obteniéndose un valor de $\hat{\lambda} = 1.3954$. Este resultado sugiere que no sería necesaria una transformación de la variable respuesta, ya que valores de λ próximos a 1 implican trabajar sobre la escala original de los datos.

No obstante, dado que la serie presenta una interrupción asociada a la pandemia de COVID-19, es posible que la estimación de λ se encuentre influenciada por dicho evento. Con el fin de evaluar esta situación, se estimó nuevamente el parámetro por separado para dos subperiodos: uno previo a la disrupción y otro posterior a ella. Los resultados obtenidos fueron $\hat{\lambda} = -0.15$ para el periodo previo y $\hat{\lambda} = 1.387$ para el periodo posterior.

Dado que los resultados obtenidos no fueron consistentes entre ambos subperiodos y considerando que el objetivo principal es reducir la heterogeneidad de la varianza observada en la serie, se optó por utilizar la transformación de logaritmo natural $\lambda = 0$. Esta transformación permite atenuar las diferencias de escala generadas por el evento disruptivo, mejorar la estabilidad de la varianza y facilitar la posterior modelización e interpretación de los resultados.

En cuanto a la estructura de dependencia temporal, la Figura 6 presenta la función de autocorrelación muestral, donde se observan valores positivos elevados en los primeros rezagos, con un decrecimiento gradual a medida que los mismos aumentan. Este patrón es característico de series no estacionarias o con fuerte dependencia temporal, lo que sugiere la necesidad de

aplicar diferenciación para estabilizar la media.

Por su parte, la Figura 7 muestra la función de autocorrelación parcial muestral, en la cual se identifica un pico significativo en el primer rezago, seguido de algunos rezagos adicionales con valores estadísticamente significativos, mientras que la mayoría de los rezagos posteriores se mantienen dentro de las bandas de confianza.




Figura 6: Función de autocorrelación muestral.






Figura 7: Función de autocorrelación parcial muestral.

Al aplicar la transformación correspondiente a la variable respuesta, en la Figura 8 se presenta la evolución temporal del logaritmo natural de los pasajeros expresado en cientos de miles, junto con su distribución anual. Se observa que el rango de la variable se reduce considerablemente, lo que contribuye a una mayor estabilidad en la varianza. Al analizar el comportamiento de la serie en los años de interés, se observa que hasta el año 2019, la variable parece ser estable en varianza pero no en media.



(a) Logaritmo natural de los pasajeros transportados por el sistema de Transporte Urbano de Pasajeros en la ciudad de Rosario.



(b) Distribución anual del logaritmo natural de los pasajeros transportados por el sistema de Transporte Urbano de Pasajeros en la ciudad de Rosario.

Figura 8: Resumen de la serie transformada

4.2 Ajuste de modelos

En esta sección se presentan los resultados del ajuste de los modelos, evaluando su capacidad para capturar la dinámica de la serie ante el evento disruptivo (año 2020) y su desempeño en la fase de recuperación (años 2021-2022) y estabilización (años 2023-2024).

Para ello, se estimaron los modelos anteriormente presentados, cuyos resultados se presentan a continuación.

4.2.1 ARIMA/SARIMA

Los modelos ARIMA/SARIMA fueron ajustados sobre la serie previamente transformada con el fin de capturar la dependencia temporal observada en el análisis exploratorio. En particular, se consideraron tanto componentes no estacionales como estacionales, permitiendo modelar adecuadamente la dinámica mensual de la serie.

Dado que el análisis se realiza bajo un esquema de evaluación por ventanas expansivas, los modelos estimados no son únicos, sino que varían en función del periodo de entrenamiento considerado. En este sentido, la Tabla 1 resume las especificaciones seleccionadas en cada una de las etapas analizadas. Cabe destacar que la amplitud de los intervalos de predicción en la fase de estabilización es muy grande, lo que refleja la alta incertidumbre residual en el modelo.

Tabla 1: Modelos ajustados en cada fase

Ventana	Modelos ajustados
1	$SARIMA(1, 0, 2)(1, 1, 0)_{12}$
2	$SARIMA(1, 1, 3)(0, 0, 2)_{12}$
3	$SARIMA(1, 1, 3)(0, 0, 2)_{12}$
4	$SARIMA(1, 1, 3)(0, 0, 1)_{12}$
5	$SARIMA(1, 1, 3)(0, 0, 2)_{12}$

En términos de desempeño predictivo, la Figura 9 presenta los pronósticos generados en cada una de las diferentes etapas. Durante el periodo del evento disruptivo, se observa que el modelo estimado no logra predecir adecuadamente la magnitud de la caída de la serie. Esto se debe a que estos modelos se basan en la información histórica, por lo que tienden a extrapolar esta información previa, replicando en cierta forma el comportamiento pasado.

En la fase de recuperación, se aprecia una mejora progresiva en la capacidad predictiva. A medida que se incorporan observaciones correspondientes al periodo posterior al evento disruptivo, estos modelos comienzan a mejorar el ajuste, reflejando parcialmente el proceso de recuperación. Sin embargo, se observan desvíos de los valores reales de la serie, lo cual indica

que la recuperación no es inmediata.

Finalmente, en la etapa de estabilización, estos modelos muestran un desempeño superior. En este periodo, la serie presenta un comportamiento más regular y predecible, lo que permite a los modelos ajustados capturar de manera más precisa su evolución. En particular, el pronóstico correspondiente al año 2024 exhibe un alto grado de concordancia con los valores reales, tanto en términos puntuales como en la cobertura de los intervalos de predicción.




Figura 9: Pronósticos utilizando modelos ARIMA/SARIMA

4.2.2 ETS


Los modelos ETS ajustados sobre la serie transformada en cada etapa corresponden a los especificados en la Tabla 2. Estas especificaciones permiten capturar la evolución del nivel, la tendencia y la estacionalidad de la serie, adaptándose a las distintas fases del periodo analizado.

Tabla 2: Modelos ajustados en cada etapa

Ventana	Modelos ajustados
1	$ETS(M, A, A)$
2	$ETS(A, N, A)$
3	$ETS(A, N, A)$
4	$ETS(A, N, A)$
5	$ETS(A, N, A)$


A diferencia de los modelos ARIMA/SARIMA, los modelos ETS presentan una mayor capacidad de adaptación frente a cambios repentinos en la dinámica de la serie. Este comportamiento se evidencia en la Figura 10, donde se observa que, si bien durante el periodo del *shock* los pronósticos resultan similares a los obtenidos mediante modelos ARIMA/SARIMA, en la fase de recuperación los modelos ETS logran ajustarse con mayor rapidez a la nueva estructura de la serie, lo que se traduce en una mejora sustancial en la calidad de los pronósticos, reflejando una capacidad superior para capturar la recuperación gradual de la serie.

Por último, en la fase de estabilización, los pronósticos generados por estos modelos se ubican próximos a los valores reales, lo que indica un buen desempeño en términos de ajuste global. Sin embargo, se observa la presencia de una mayor incertidumbre asociada a las predicciones, reflejada en la amplitud de los intervalos de pronóstico.




Intervalo de predicción 80%

(a) Pronóstico año 2020




Intervalo de predicción 80%

(b) Pronóstico año 2021




Intervalo de predicción 80%

(c) Pronóstico año 2022



Intervalo de predicción 80%

(d) Pronóstico año 2023



Intervalo de predicción 80%

(e) Pronóstico año 2024

Figura 10: Pronósticos utilizando ETS

4.2.3 Modelos de intervención

Estos modelos requieren definir variables explicativas que representen la intervención sobre la serie. Se estableció una variable indicadora ($x_{1,t}$) de la siguiente manera:

$$x_{1,t} = \begin{cases} 1 & \text{si } t \in \text{Marzo 2020 - Julio 2021} \\ 0 & \text{en otro caso} \end{cases} \quad (34)$$

Esta variable captura la drástica reducción en la utilización del servicio público debido al Aislamiento Social, Preventivo y Obligatorio (ASPO) establecido en Argentina a partir del 20 de marzo de 2020.


Adicionalmente, con el fin de enriquecer la especificación del modelo, se incorporó una segunda variable indicadora ($x_{2,t}$) con el objetivo que la misma capture el aumento progresivo y no lineal de la demanda del servicio. La misma se la define como:

$$x_{2,t} = \begin{cases} 1 & \text{si } t \in \text{Agosto 2021 - Diciembre 2024} \\ 0 & \text{en otro caso} \end{cases} \quad (35)$$

Tabla 3: Modelos ajustados en cada fase


Ventana	Modelos ajustados
1	$SARIMA(1, 0, 2)(1, 1, 0)_{12}$
2	$SARIMA(0, 1, 1)(0, 0, 1)_{12}$
3	$SARIMA(1, 0, 2)(0, 0, 2)_{12}$
4	$SARIMA(1, 0, 2)(0, 0, 2)_{12}$
5	$SARIMA(1, 0, 2)(0, 0, 2)_{12}$

En este enfoque, se puede observar en la Figura 11 que estos modelos presentan limitaciones para adaptarse con rapidez al evento disruptivo, dado que en la fase de recuperación los pronósticos se encuentran muy lejos de los valores reales. Recién en la fase de estabilización, los pronósticos comienzan a aproximarse a la verdadera trayectoria de la serie.




Intervalo de predicción 80%

(a) Pronóstico año 2020




Intervalo de predicción 80%

(b) Pronóstico año 2021




Intervalo de predicción 80%

(c) Pronóstico año 2022



Intervalo de predicción 80%

(d) Pronóstico año 2023



Intervalo de predicción 80%

(e) Pronóstico año 2024

Figura 11: Pronósticos utilizando modelos de intervención

4.2.4 Métodos contrafactuales

4.2.4.1 Establecer como faltante (*set to missing*)

En este enfoque, se establece como faltantes aquellas observaciones que pertenecen al periodo disruptivo comprendido entre Marzo de 2020 y Julio de 2021, afectando directamente a todas aquellas ventanas de ajuste y pronóstico que incluyan dicho intervalo.




Figura 12: Pasajeros transportados por el sistema de Transporte Urbano de Pasajeros en la ciudad de Rosario. El periodo entre Marzo 2020 a Julio 2021 se estableció como faltante

Tabla 4: Modelos ajustados en cada fase

Ventana	Modelos ajustados
1	$SARIMA(1, 0, 2)(1, 1, 0)_{12}$
2	$SARIMA(1, 0, 2)(1, 1, 0)_{12}$
3	$SARIMA(1, 0, 2)(1, 1, 0)_{12}$
4	$SARIMA(1, 0, 2)(1, 1, 0)_{12}$
5	$SARIMA(1, 0, 2)(0, 1, 0)_{12}$

Como consecuencia, el modelo no toma en cuenta la caída abrupta observada durante la pandemia, sino que extrapola la dinámica previa a la misma. En la Figura 13 se puede observar que los pronósticos durante los años 2020 y 2021 están muy por encima de los valores reales, comportamiento que resulta esperable dado que no se consideran esas observaciones durante el ajuste de los modelos.

Sin embargo, luego del periodo disruptivo, la capacidad predictiva del modelo mejora de manera considerable. En los años posteriores, los pronósticos comienzan a aproximarse a los valores observados.




Figura 13: Pronósticos utilizando modelos contrafactuales ‘STM’

4.2.4.2 Lo que podría haber ocurrido (*what might have been*)

A diferencia del método anterior, en este caso se opta por imputar los valores faltantes correspondientes al periodo comprendido entre Marzo 2020 - Julio 2021. Para ello, se reemplazó cada observación faltante por el promedio de cada mes utilizando las observaciones de los 3 años previos al inicio de la interrupción.




Figura 14: Pasajeros transportados por el sistema de Transporte Urbano de Pasajeros en la ciudad de Rosario. El periodo entre Marzo 2020 a Julio 2021 se reconstruyó utilizando el promedio de cada mes con los 3 años previos a Marzo 2020.

Tabla 5: Modelos ajustados en cada fase

Ventana	Modelos ajustados
1	$SARIMA(1, 0, 2)(1, 1, 0)_{12}$
2	$SARIMA(2, 0, 3)(0, 1, 1)_{12}$
3	$SARIMA(2, 0, 0)(0, 1, 1)_{12}$
4	$SARIMA(1, 0, 2)(0, 1, 1)_{12}$
5	$SARIMA(1, 0, 1)(2, 1, 1)_{12}$

No obstante, durante la fase de recuperación se observa que este método no logra adaptarse adecuadamente a los cambios abruptos en la dinámica de la serie, dado que la imputación se basa exclusivamente en información previa a la disrupción y, por lo tanto, no incorpora la nueva dinámica de la demanda del servicio. En consecuencia, los errores de pronóstico tienden a ser elevados.

Sin embargo, tal como se muestra en la Figura 15, a medida que se incorporan nuevas observaciones reales al proceso de estimación, los modelos comienzan a ajustarse progresivamente, generando pronósticos cada vez más cercanos a los valores reales, reduciendo considerablemente los errores de pronóstico. Este comportamiento evidencia una mayor capacidad de adaptación en el mediano y largo plazo.




Figura 15: Pronósticos utilizando modelos contrafactuales 'WMHB'


4.2.5 Ensemble

En este enfoque se propone una estrategia de combinación de pronósticos, integrando las cuatro metodologías consideradas mediante un promedio simple. Esta aproximación busca aprovechar la información complementaria de cada modelo, reduciendo la variabilidad individual y mejorando la robustez de las predicciones.

Para la construcción de los intervalos de predicción, se generan múltiples trayectorias simuladas para cada uno de los modelos individuales y posteriormente se combinan en una única distribución predictiva conjunta. A partir de esta distribución, los intervalos se obtienen mediante cuantiles empíricos asociados al nivel de cobertura seleccionado, en este caso 80%, permitiendo reflejar tanto la incertidumbre propia de cada modelo como la variabilidad derivada de la estrategia de combinación.


Tal como se observa en la Figura 16, los pronósticos obtenidos mediante esta estrategia presentan una adaptación más rápida frente a los cambios abruptos en comparación con los enfoques individuales, lo cual constituye una evidencia de su capacidad para responder ante fases tempranas de eventos disruptivos. Asimismo, en las ventanas de pronóstico posteriores, los valores estimados se mantienen cercanos a los observados, reflejando un desempeño consistente a lo largo del tiempo.

Por lo tanto, estos resultados indican que la estrategia de combinación puede contribuir a mejorar la precisión predictiva y la estabilidad de los pronósticos, posicionándose como una buena alternativa frente a este tipo de escenarios.




Intervalo de predicción 80%

(a) Pronóstico año 2020




Intervalo de predicción 80%

(b) Pronóstico año 2021




Intervalo de predicción 80%

(c) Pronóstico año 2022



Intervalo de predicción 80%

(d) Pronóstico año 2023



Intervalo de predicción 80%

(e) Pronóstico año 2024

Figura 16: Pronósticos utilizando Ensemble

4.3 Resultados comparativos de pronóstico

Para evaluar el desempeño predictivo de los distintos modelos en cada ventana de pronóstico se utilizaron métricas de capacidad predictiva puntual y de calidad del intervalo de pronóstico los cuales fueron construidos utilizando una probabilidad de cobertura del 80%.

Los resultados obtenidos muestran que durante el año 2020 todos los enfoques presentan errores elevados como consecuencia de la ocurrencia del evento disruptivo, así como una limitada capacidad de adaptación ante cambios abruptos por parte de los modelos tradicionales (ARIMA/SARIMA). En este periodo, se observa un deterioro generalizado en todas las métricas, acompañado de intervalos de predicción menos informativos.

Por otra parte, los métodos de combinación evidencian un desempeño superior, reflejado en una menor magnitud de error y una mejor calidad de los intervalos de predicción. Esta mejora resulta especialmente notable tanto en las fases tempranas posteriores al quiebre estructural como en el mediano y largo plazo. En este contexto, los métodos contrafactuales, más específicamente (*what might have been*), muestra un comportamiento destacado entre los enfoques individuales, evidenciando una rápida mejora y una adecuada adaptación a medida que transcurre el tiempo.

A su vez, a medida que se incorporan nuevas observaciones y los modelos logran capturar la nueva dinámica de la serie, todos los enfoques tienden a converger hacia un buen desempeño en el largo plazo, reflejado en la disminución progresiva de los errores y en una mejora en la calidad de los intervalos de predicción.

Tabla 6: Evaluación de los pronósticos usando (RMSE) para cada enfoque

Estrategia	2020	2021	2022	2023	2024
ARIMA	72.6188	39.8946	44.4757	15.7846	7.8482
ETS	73.5476	27.6106	7.6389	8.8325	16.4607
Regresión Dinámica	72.6188	48.2336	35.2806	21.0903	11.1204
STM	72.6188	43.5942	17.8111	15.8258	14.2177
WMHB	72.6188	51.7077	6.4751	6.7116	11.2510
Ensemble	72.8024	11.2208	19.6805	12.5617	9.4374

Tabla 7: Evaluación de los pronósticos usando (MAE) para cada enfoque

Estrategia	2020	2021	2022	2023	2024
ARIMA	65.2824	35.6734	41.2118	14.0559	5.9100
ETS	66.2331	24.9127	6.8219	6.9264	12.1061
Regresión Dinámica	65.2824	40.4633	32.0100	18.6567	9.6294
STM	65.2824	41.3842	16.1269	14.5379	11.5649
WMHB	65.2824	49.8611	5.1969	5.1991	7.7184
Ensemble	65.4713	8.9914	17.9613	10.6388	5.4565

Tabla 8: Evaluación de los pronósticos usando (MAPE) para cada enfoque

Estrategia	2020	2021	2022	2023	2024
ARIMA	782.3700	62.3211	51.3059	14.7926	7.7671
ETS	787.5277	42.8660	9.5705	7.5814	15.5987
Regresión Dinámica	782.3700	72.2868	40.9031	19.4196	11.1595
STM	782.3700	88.4641	19.7778	15.5554	14.4000
WMHB	782.3700	104.6633	7.5828	5.2990	10.1835
Ensemble	783.4745	19.5210	22.9699	10.8759	7.5188

Tabla 9: Evaluación de los pronósticos usando (Puntuación de Winkler) para cada enfoque

Estrategia	2020	2021	2022	2023	2024
ARIMA	599.2769	280.7661	243.4410	85.3179	92.5032
ETS	615.1908	114.7553	90.6417	92.7460	105.5659
Regresión Dinámica	599.2769	266.8093	184.4661	58.3325	58.9032
STM	599.2769	344.1494	112.1934	81.4613	48.2305
WMHB	599.2769	440.1319	26.2719	22.7540	43.7482
Ensemble	601.8546	102.1934	64.1796	58.7224	64.0629

4.4 Diagnóstico y validación de modelos

Con el objetivo de evaluar la adecuación de los modelos ajustados, se realizó un análisis diagnóstico de los residuos asociados a cada una de las metodologías consideradas. En particular, se analizaron gráficamente los residuos, las funciones de autocorrelación residual (ACF) y los histogramas correspondientes, complementando dicho análisis mediante el test de Ljung-Box para evaluar la presencia de autocorrelación residual significativa.

Los gráficos diagnósticos completos se presentan en el Anexo, junto con los resultados asociados a cada modelo analizado.

Los diagnósticos residuales evidenciaron que ninguno de los modelos analizados cumplió de manera estricta con la totalidad de los supuestos clásicos. Sin embargo, estas limitaciones resultan consistentes con la complejidad inherente a una serie temporal afectada por cambios estructurales abruptos y altos niveles de volatilidad, como los observados durante la pandemia de COVID-19.

En este sentido, los resultados obtenidos muestran que un ajuste residual menos “ideal” desde el punto de vista teórico no necesariamente implica un peor desempeño predictivo. De hecho, aun ante el incumplimiento de los supuestos, aquellos modelos que lograron adaptarse con mayor rapidez a los nuevos patrones de comportamiento de la serie, obtuvieron pronósticos más precisos durante la etapa de recuperación.

Dicha evidencia refuerza una de las principales conclusiones metodológicas del trabajo: en contextos de series temporales interrumpidas, la capacidad adaptativa de los modelos puede adquirir mayor relevancia práctica que el cumplimiento estricto de ciertos supuestos clásicos asociados a escenarios de estabilidad estructural. Esto resulta consistente con los hallazgos observados en la comparación empírica de pronósticos y constituye uno de los principales aportes metodológicos de la presente investigación.

5. Conclusión

La presente investigación permitió evaluar diversas estrategias para la modelización y pronóstico de series temporales interrumpidas, utilizando como caso de estudio el flujo de pasajeros del Transporte Urbano de Rosario (TUP) durante el impacto de la pandemia de COVID-19.

Los resultados obtenidos evidencian que los modelos tradicionales ARIMA/SARIMA, si bien constituyen una herramienta ampliamente utilizada, presentan limitaciones importantes frente a eventos disruptivos. En particular, durante el periodo en el que ocurre la disrupción y la etapa de recuperación, estos modelos mostraron una menor capacidad de adaptación a los nuevos patrones de comportamiento de la demanda, reflejada en mayores errores de predicción.

Por el contrario, los modelos altamente adaptativos (ETS) demostraron una mejor capacidad para ajustarse a las variaciones recientes de la serie, capturando con mayor rapidez las modificaciones en la tendencia y en la estacionalidad. Esta característica permitió obtener pronósticos más precisos durante las fases de recuperación y estabilización, especialmente en este contexto donde los patrones históricos dejaron de ser representativos del comportamiento futuro.

Asimismo, los modelos de intervención permitieron incorporar explícitamente el efecto del *shock* y su posterior recuperación mediante variables explicativas. No obstante, los resultados reflejaron una capacidad limitada de adaptación ante escenarios caracterizados por cambios abruptos y elevada incertidumbre.

Por otro lado, los enfoques contrafactuales aportaron una perspectiva distinta al análisis, permitiendo reconstruir escenarios alternativos acerca de cómo habría evolucionado la demanda del transporte urbano. Ambas estrategias mostraron ventajas para reducir la influencia de observaciones extremadamente atípicas durante el ajuste de los modelos, contribuyendo a generar pronósticos más estables en el periodo posterior a la interrupción.

Por último, los resultados obtenidos utilizando la estrategia de combinación (*ensemble*) muestran un desempeño altamente competitivo y robusto frente a los distintos escenarios considerados. Dicha combinación permitió mitigar debilidades individuales de cada modelo y potenciar las fortalezas de cada uno de ellos, resultando en una de las estrategias más adecuadas para aplicar ante situaciones extremas.

Sin embargo, el análisis comparativo realizado pone de manifiesto que el rendimiento de las distintas metodologías varía considerablemente según la etapa del periodo disruptivo analizado. En consecuencia, no puede afirmarse la existencia de un método óptimo en términos generales, sino más bien de enfoques relativamente más adecuados dependiendo de la fase considerada.

En concordancia con los desarrollos recientes de Hyndman y Rostami-Tabar (2024), esta

investigación confirma que, en contextos de series interrumpidas, la prioridad debe desplazarse de la “pureza estadística” de los residuos hacia la adaptabilidad del pronóstico. Se observó que, aunque algunos enfoques presentaban ciertas desviaciones en los supuestos de normalidad o independencia de residuos (producto de la volatilidad extrema del periodo), su desempeño predictivo fue superior. Los resultados observados muestran que la capacidad de un modelo para adaptarse a una “nueva normalidad” puede resultar más relevante que el cumplimiento estricto de determinados supuestos clásicos cuando el objetivo principal es obtener pronósticos precisos en contextos de alta incertidumbre.

6. Aporte y futuras líneas

La principal contribución de esta tesina consiste en aportar evidencia empírica sobre el desempeño de distintas estrategias de pronóstico aplicadas a series temporales interrumpidas, a partir del análisis de un caso de estudio real y de relevancia social como la movilidad urbana en la ciudad de Rosario durante y después de la pandemia de COVID-19.

Desde una perspectiva aplicada, los resultados obtenidos proporcionan herramientas útiles para organismos vinculados a la planificación y gestión del transporte urbano, particularmente para el **Ente de la Movilidad de Rosario (EMR)**. La identificación de metodologías más robustas frente a *shocks* exógenos permite mejorar la capacidad de respuesta ante situaciones inusuales, facilitando el proceso de toma de decisiones estratégicas y operativas.

Además, el trabajo evidencia que los cambios producidos por la pandemia no constituyen únicamente perturbaciones transitorias, sino que pueden generar modificaciones persistentes en los patrones de movilidad urbana. En este sentido, los resultados obtenidos refuerzan la importancia de utilizar enfoques de modelización capaces de adaptarse a cambios estructurales y dinámicas no lineales en la evolución de la demanda.

Desde el punto de vista metodológico, la investigación aporta evidencia empírica sobre el comportamiento diferencial de diversas estrategias de pronóstico frente a series afectadas por eventos disruptivos, mostrando que la adaptabilidad de los modelos puede desempeñar un rol central en contextos caracterizados por elevada volatilidad e incertidumbre.

Como extensión de esta investigación, se sugiere explorar la incorporación de variables exógenas relevantes que permitan enriquecer la modelización, así como evaluar el uso de modelos de aprendizaje automático (*Machine Learning*) y aprendizaje profundo (*Deep Learning*), como por ejemplo, *Random Forest*, *XGBoost*, redes neuronales recurrentes (RNN), entre otros, con el objetivo de capturar dinámicas no lineales tanto en la fase de recuperación como en horizontes de largo plazo.

7. Anexo

Todo el desarrollo de la tesis se puede encontrar en el siguiente repositorio de [Github](#)




Figura 17: Residuos modelo $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Tabla 10: Test de Ljung-Box cada 12 rezagos del modelo $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Lag	Estadística	P-Valor
12	18.9593	0.0895
24	54.2651	0.0004
36	70.5073	0.0005
48	102.8047	0.0000
60	114.4630	0.0000
72	133.1977	0.0000

Tabla 11: Tests de normalidad del modelo $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9515	0.0000
Lilliefors	0.1042	0.0001




Figura 18: Residuos modelo $SARIMA(1, 1, 3)(0, 0, 2)_{12}$

Tabla 12: Test de Ljung-Box cada 12 rezagos del modelo $SARIMA(1, 1, 3)(0, 0, 2)_{12}$

Lag	Estadística	P-Valor
12	7.7827	0.8019
24	11.4182	0.9857
36	14.4312	0.9995
48	19.3557	0.9999
60	21.7342	1.0000
72	23.9572	1.0000

Tabla 13: Tests de normalidad del modelo $SARIMA(1, 1, 3)(0, 0, 2)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.5496	0
Lilliefors	0.2367	0




Figura 19: Residuos modelo $SARIMA(1, 1, 3)(0, 0, 2)_{12}$

Tabla 14: Test de Ljung-Box cada 12 rezagos del modelo $SARIMA(1, 1, 3)(0, 0, 2)_{12}$

Lag	Estadística	P-Valor
12	11.7830	0.4633
24	28.0493	0.2580
36	34.5299	0.5385
48	42.4192	0.7000
60	47.5379	0.8781
72	52.1960	0.9620

Tabla 15: Tests de normalidad del modelo $SARIMA(1, 1, 3)(0, 0, 2)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.6250	0
Lilliefors	0.2117	0




Figura 20: Residuos modelo $SARIMA(1, 1, 3)(0, 0, 1)_{12}$

Tabla 16: Test de Ljung-Box cada 12 rezagos del modelo $SARIMA(1, 1, 3)(0, 0, 1)_{12}$

Lag	Estadística	P-Valor
12	13.0010	0.3690
24	34.5292	0.0757
36	48.8680	0.0746
48	63.6890	0.0642
60	75.2551	0.0886
72	86.1440	0.1222

Tabla 17: Tests de normalidad del modelo $SARIMA(1, 1, 3)(0, 0, 1)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.6828	0
Lilliefors	0.1854	0




Figura 21: Residuos modelo $SARIMA(1, 1, 3)(0, 0, 2)_{12}$

Tabla 18: Test de Ljung-Box cada 12 rezagos del modelo $SARIMA(1, 1, 3)(0, 0, 2)_{12}$

Lag	Estadística	P-Valor
12	12.4651	0.4091
24	30.5371	0.1676
36	41.1662	0.2547
48	53.0256	0.2865
60	63.5988	0.3509
72	73.5161	0.4282

Tabla 19: Tests de normalidad del modelo $SARIMA(1, 1, 3)(0, 0, 2)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.6716	0
Lilliefors	0.1964	0




Figura 22: Residuos modelo $ETS(M, A, A)$

Tabla 20: Test de Ljung-Box cada 12 rezagos del modelo $ETS(M, A, A)$

Lag	Estadística	P-Valor
12	24.0446	0.0201
24	56.8060	0.0002
36	79.4800	0.0000
48	126.2730	0.0000
60	149.4403	0.0000
72	167.4419	0.0000

Tabla 21: Tests de normalidad del modelo $ETS(M, A, A)$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9512	0.0000
Lilliefors	0.0893	0.0023




Figura 23: Residuos modelo $ETS(A, N, A)$

Tabla 22: Test de Ljung-Box cada 12 rezagos del modelo $ETS(A, N, A)$

Lag	Estadística	P-Valor
12	62.8370	0.0000
24	63.2044	0.0000
36	63.6618	0.0030
48	64.4861	0.0562
60	65.2454	0.2994
72	65.8333	0.6820

Tabla 23: Tests de normalidad del modelo $ETS(A, N, A)$

Test	Estadística	P-Valor
Shapiro-Wilk	0.4856	0
Lilliefors	0.2831	0




Figura 24: Residuos modelo $ETS(A, N, A)$

Tabla 24: Test de Ljung-Box cada 12 rezagos del modelo $ETS(A, N, A)$

Lag	Estadística	P-Valor
12	59.0713	0.0000
24	62.7397	0.0000
36	63.3778	0.0032
48	64.1466	0.0595
60	64.7099	0.3157
72	65.3430	0.6974

Tabla 25: Tests de normalidad del modelo $ETS(A, N, A)$

Test	Estadística	P-Valor
Shapiro-Wilk	0.5648	0
Lilliefors	0.2639	0




Figura 25: Residuos modelo $ETS(A, N, A)$

Tabla 26: Test de Ljung-Box cada 12 rezagos del modelo $ETS(A, N, A)$

Lag	Estadística	P-Valor
12	65.0866	0.0000
24	69.4057	0.0000
36	70.8451	0.0005
48	71.2864	0.0162
60	71.8087	0.1413
72	72.3121	0.4675

Tabla 27: Tests de normalidad del modelo $ETS(A, N, A)$

Test	Estadística	P-Valor
Shapiro-Wilk	0.5528	0
Lilliefors	0.2608	0




Figura 26: Residuos modelo $ETS(A, N, A)$

Tabla 28: Test de Ljung-Box cada 12 rezagos del modelo $ETS(A, N, A)$

Lag	Estadística	P-Valor
12	65.1014	0.0000
24	69.4092	0.0000
36	73.8037	0.0002
48	75.6519	0.0066
60	76.0647	0.0789
72	76.5509	0.3347

Tabla 29: Tests de normalidad del modelo $ETS(A, N, A)$

Test	Estadística	P-Valor
Shapiro-Wilk	0.5397	0
Lilliefors	0.2781	0




Figura 27: Residuos modelo intervención $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Tabla 30: Test de Ljung-Box cada 12 rezagos del modelo intervención $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Lag	Estadística	P-Valor
12	18.9593	0.0895
24	54.2651	0.0004
36	70.5073	0.0005
48	102.8047	0.0000
60	114.4630	0.0000
72	133.1977	0.0000

Tabla 31: Tests de normalidad del modelo $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9515	0.0000
Lilliefors	0.1042	0.0001




Figura 28: Residuos modelo intervención $SARIMA(0, 1, 1)(0, 0, 1)_{12}$

Tabla 32: Test de Ljung-Box cada 12 rezagos del modelo intervención $SARIMA(0, 1, 1)(0, 0, 1)_{12}$

Lag	Estadística	P-Valor
12	33.0567	0.0009
24	36.7860	0.0460
36	40.3826	0.2827
48	44.2047	0.6291
60	46.7822	0.8937
72	49.3340	0.9811

Tabla 33: Tests de normalidad del modelo $SARIMA(0, 1, 1)(0, 0, 1)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.5685	0
Lilliefors	0.2354	0




Figura 29: Residuos modelo intervención $SARIMA(1, 0, 2)(0, 0, 2)_{12}$

Tabla 34: Test de Ljung-Box cada 12 rezagos del modelo intervención $SARIMA(1, 0, 2)(0, 0, 2)_{12}$

Lag	Estadística	P-Valor
12	12.9518	0.3726
24	33.8959	0.0865
36	40.8800	0.2647
48	50.0784	0.3909
60	57.2829	0.5756
72	62.0047	0.7935

Tabla 35: Tests de normalidad del modelo $SARIMA(1, 0, 2)(0, 0, 2)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.6167	0
Lilliefors	0.2005	0




Figura 30: Residuos modelo intervención $SARIMA(1, 0, 2)(0, 0, 2)_{12}$

Tabla 36: Test de Ljung-Box cada 12 rezagos del modelo intervención $SARIMA(1, 0, 2)(0, 0, 2)_{12}$

Lag	Estadística	P-Valor
12	10.3480	0.5855
24	29.4428	0.2039
36	44.2464	0.1627
48	55.8802	0.2029
60	65.6255	0.2882
72	73.4846	0.4292

Tabla 37: Tests de normalidad del modelo $SARIMA(1, 0, 2)(0, 0, 2)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.6686	0
Lilliefors	0.1795	0




Figura 31: Residuos modelo intervención $SARIMA(1, 0, 2)(0, 0, 2)_{12}$

Tabla 38: Test de Ljung-Box cada 12 rezagos del modelo intervención $SARIMA(1, 0, 2)(0, 0, 2)_{12}$

Lag	Estadística	P-Valor
12	11.4121	0.4940
24	33.4783	0.0944
36	47.5438	0.0944
48	63.0911	0.0708
60	74.2136	0.1026
72	83.0829	0.1749

Tabla 39: Tests de normalidad del modelo $SARIMA(1, 0, 2)(0, 0, 2)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.6680	0
Lilliefors	0.1833	0




Figura 32: Residuos modelo stm $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Tabla 40: Test de Ljung-Box cada 12 rezagos del modelo stm $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Lag	Estadística	P-Valor
12	18.9593	0.0895
24	54.2651	0.0004
36	70.5073	0.0005
48	102.8047	0.0000
60	114.4630	0.0000
72	133.1977	0.0000

Tabla 41: Tests de normalidad del modelo $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9515	0.0000
Lilliefors	0.1042	0.0001




Figura 33: Residuos modelo stm $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Tabla 42: Test de Ljung-Box cada 12 rezagos del modelo stm $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Lag	Estadística	P-Valor
12	18.1503	0.1112
24	54.8710	0.0003
36	71.2063	0.0004
48	105.2798	0.0000
60	117.7622	0.0000
72	136.0992	0.0000

Tabla 43: Tests de normalidad del modelo $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9532	0.0000
Lilliefors	0.1044	0.0001




Figura 34: Residuos modelo stm $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Tabla 44: Test de Ljung-Box cada 12 rezagos del modelo stm $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Lag	Estadística	P-Valor
12	20.2430	0.0626
24	48.5182	0.0022
36	62.4468	0.0041
48	96.0988	0.0000
60	109.2681	0.0001
72	133.5928	0.0000

Tabla 45: Tests de normalidad del modelo $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9349	0
Lilliefors	0.1120	0




Figura 35: Residuos modelo stm $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Tabla 46: Test de Ljung-Box cada 12 rezagos del modelo stm $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Lag	Estadística	P-Valor
12	30.1195	0.0027
24	62.1587	0.0000
36	76.4839	0.0001
48	114.5713	0.0000
60	128.8785	0.0000
72	166.1395	0.0000

Tabla 47: Tests de normalidad del modelo $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9537	0.0000
Lilliefors	0.0933	0.0004




Figura 36: Residuos modelo stm $SARIMA(1, 0, 2)(0, 1, 0)_{12}$

Tabla 48: Test de Ljung-Box cada 12 rezagos del modelo stm $SARIMA(1, 0, 2)(0, 1, 0)_{12}$

Lag	Estadística	P-Valor
12	54.6899	0
24	78.3675	0
36	90.3330	0
48	120.5547	0
60	133.1155	0
72	158.7555	0

Tabla 49: Tests de normalidad del modelo $SARIMA(1, 0, 2)(0, 1, 0)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9632	0
Lilliefors	0.1096	0




Figura 37: Residuos modelo $wmhb\ SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Tabla 50: Test de Ljung-Box cada 12 rezagos del modelo $wmhb\ SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Lag	Estadística	P-Valor
12	18.9593	0.0895
24	54.2651	0.0004
36	70.5073	0.0005
48	102.8047	0.0000
60	114.4630	0.0000
72	133.1977	0.0000

Tabla 51: Tests de normalidad del modelo $SARIMA(1, 0, 2)(1, 1, 0)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9515	0.0000
Lilliefors	0.1042	0.0001




Figura 38: Residuos modelo wmhb $SARIMA(2, 0, 3)(0, 1, 1)_{12}$

Tabla 52: Test de Ljung-Box cada 12 rezagos del modelo wmhb $SARIMA(2, 0, 3)(0, 1, 1)_{12}$

Lag	Estadística	P-Valor
12	15.6706	0.2068
24	41.0328	0.0165
36	50.9550	0.0504
48	79.4907	0.0029
60	95.0778	0.0026
72	113.3171	0.0014

Tabla 53: Tests de normalidad del modelo $SARIMA(2, 0, 3)(0, 1, 1)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.9474	0
Lilliefors	0.1074	0




Figura 39: Residuos modelo $wmhb\ SARIMA(2, 0, 0)(0, 1, 1)_{12}$

Tabla 54: Test de Ljung-Box cada 12 rezagos del modelo $wmhb\ SARIMA(2, 0, 0)(0, 1, 1)_{12}$

Lag	Estadística	P-Valor
12	6.5982	0.8830
24	18.1709	0.7946
36	28.7450	0.7996
48	41.0159	0.7523
60	51.4224	0.7770
72	66.7743	0.6519

Tabla 55: Tests de normalidad del modelo $SARIMA(2, 0, 0)(0, 1, 1)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.6603	0
Lilliefors	0.1462	0




Figura 40: Residuos modelo wmhb $SARIMA(1, 0, 2)(0, 1, 1)_{12}$

Tabla 56: Test de Ljung-Box cada 12 rezagos del modelo wmhb $SARIMA(1, 0, 2)(0, 1, 1)_{12}$

Lag	Estadística	P-Valor
12	18.0664	0.1137
24	33.6761	0.0906
36	40.5770	0.2756
48	54.9764	0.2274
60	64.9159	0.3094
72	82.5085	0.1864

Tabla 57: Tests de normalidad del modelo $SARIMA(1, 0, 2)(0, 1, 1)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.6893	0
Lilliefors	0.1484	0




Figura 41: Residuos modelo wmhb $SARIMA(1, 0, 1)(2, 1, 1)_{12}$

Tabla 58: Test de Ljung-Box cada 12 rezagos del modelo wmhb $SARIMA(1, 0, 1)(2, 1, 1)_{12}$

Lag	Estadística	P-Valor
12	17.2195	0.1415
24	36.8714	0.0451
36	46.0580	0.1216
48	60.6851	0.1034
60	69.3161	0.1921
72	86.0766	0.1232

Tabla 59: Tests de normalidad del modelo $SARIMA(1, 0, 1)(2, 1, 1)_{12}$

Test	Estadística	P-Valor
Shapiro-Wilk	0.6981	0
Lilliefors	0.1427	0




Figura 42: Evaluación de los pronósticos usando (RMSE) para cada enfoque




Figura 43: Evaluación de los pronósticos usando (MAE) para cada enfoque




Figura 44: Evaluación de los pronósticos usando (MAPE) para cada enfoque. Se omite el año 2020, cuyos valores cercanos al 780% comprimen la escala e impiden distinguir el desempeño relativo de las estrategias.




Figura 45: Evaluación de los pronósticos usando (Puntuación de Winkler) para cada enfoque

8. Bibliografía

Box, G. E. P., & Tiao, G. C. (1975). Intervention analysis with applications to economic and environmental problems. *Journal of the American Statistical Association*, 70(349), 70–79.

Gardner, E. S. (2006). Exponential smoothing: The state of the art — Part II. *International Journal of Forecasting*, 22, 637–666. <https://doi.org/10.1016/j.ijforecast.2006.03.005>

Hendry, D. F., & Clements, M. P. (2004). Pooling of forecasts. *The Econometrics Journal*, 7(1), 1–31.

Hyndman, R. J. (2014). Measuring forecast accuracy. In *Business Forecasting: Practical Problems and Solutions*, 177–183.

Hyndman, R. J., & Rostami-Tabar, B. (2024). Forecasting interrupted time series. *Journal of the Operational Research Society*, 76(4), 790–803. <https://doi.org/10.1080/01605682.2024.2395315>

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>

Peña, D. (2005). *Análisis de series temporales*. Alianza Editorial.

Tulio, I. O. (2024). *Análisis de los cambios en el sistema de transporte urbano de pasajeros de la ciudad de Rosario mediante el enfoque de series temporales ARIMA-SARIMA para el período 2006-2024*.

Wang, X., Hyndman, R. J., Li, F., & Kang, Y. (2023). Forecast combinations: an over 50-year review. *International Journal of Forecasting*, 39(4), 1518–1547. <https://robjhyndman.com/publications/combinations/>

Wei, W. W. S. (2006). *Time Series Analysis: Univariate and Multivariate Methods* (2nd ed.). Pearson Education.

Wu, S.-F., Chang, C.-Y., & Lee, S.-J. (2015). Time series forecasting with missing values. In *2015 1st International Conference on Industrial Networks and Intelligent Systems (INISCom)* (pp. 151–156). <https://doi.org/10.4108/icst.iniscom.2015.258269>